Relatório de Limpeza de Dados

De início, nos familiarizamos com os dados, vendo quais informações estavam armazenadas e como foram guardadas. Como havia vários registros, pedimos ao ChatGPT para procurar por irregularidades nos atributos. Ele então nos apontou pontos que mereciam ser verificados.

Quedas nos edifícios afetados:

Bairro	Nível anterior	Afetadas antes	Nível seguinte	Afetadas depois	Queda
Arquipélago	3_0m	4.685	3_1m	4.680	5
Espírito Santo	3_3m	637	3_4m	633	4
Espírito Santo	3_4m	633	3_5m	25	608
Arquipélago	3_5m	4.685	3_6m	4.680	5
Arquipélago	4_0m	4.685	4_1m	4.674	11
Arquipélago	4_5m	4.685	4_6m	4.680	5
Espírito Santo	4_7m	2.101	4_8m	47	2.054
Arquipélago	5_0m	4.685	5_1m	4.680	5
Arquipélago	5_3m	4.688	5_4m	4.680	8
Lageado	8_0m	108	8_1m	0	108
Rubem Berta	8_7m	252	8_8m	0	252
Centro Histórico	9_6m	2.050	9_7m	0	2.050

Quedas na população afetada:

Bairro	Nível anterior	Pop. afetada antes	Nível seguinte	Pop. afetada depois	Queda
Espírito Santo	3_3m	991	3_4m	942	49
Espírito Santo	3_4m	942	3_5m	50	892
Espírito Santo	4_7m	3.121	4_8m	100	3.021
Lageado	8_0m	171	8_1m	0	171
Rubem Berta	8_7m	1.118	8_8m	0	1.118
Centro Histórico	9_6m	14.674	9_7m	0	14.674

Divergências nos percentuais:

Bairro	Nível	Afetadas / total	Percentual no JSON	Esperado
Boa Vista do Sul	7_2m	686 / 2.450 = 28.00%	29%	28%
Boa Vista do Sul	7_3m	686 / 2.450 = 28.00%	29%	28%

Com isso, fomos verificar cada caso individualmente. Começando por Lageado, Rubem Berta e Centro Histórico que tinham o mesmo problema. Nos respectivos intervalos acima, o número de edifícios e população simplesmente zeraram. Com isso, pegamos os valores respectivos de edifícios e população anteriores e posteriores e fizemos a média, preenchendo cada um deles individualmente.

No bairro Lageado, por exemplo, o nível de 8,1 m estava zerado, então preenchemos com 109 edifícios afetados (média entre 108 no nível 8,0 m e 110 no nível 8,2 m) e 199 pessoas afetadas (média entre 171 e 228). No Centro Histórico, observamos que essas quedas para zero ocorreram nos níveis 9,7 m e 9,8 m, antes dos registros retornarem para 2.130 edifícios no nível 9,9 m, exigindo o preenchimento proporcional dessa lacuna.

O bairro Arquipélago possuía total de edifícios como 4.688 e a porcentagem de afetamento era 100%, porém, nos registros sempre estavam em 4.685 edifícios afetados. Além de nos intervalos 3,1 m, 3,6 m, 4,1 m, 4,6 m e 5,1 m os números de edifícios afetados diminuíram. Dada a porcentagem então, colocamos o valor de edifícios afetados em 4.688 para todos os intervalos.

Os registros de Espírito Santo eram os mais bagunçados. Alguns valores chamaram atenção por não acompanharem a subida do rio. No nível de 4,7 m, o número de edifícios afetados pulou para 2.101, enquanto em 4,6 m eram só 46 e em 4,8 m, 47.

Com a população afetada aconteceu o mesmo. Em 4,7 m apareceram 3.121 pessoas, bem acima das 50 a 100 pessoas registradas entre 3,5 m e 4,6 m, e das 100 pessoas em 4,8 m. Outro problema apareceu no começo da série: havia quase 1.000 pessoas afetadas em 3,3 m e 3,4 m, mas esse número caía de repente a partir de 3,5 m, sem explicação.

Para corrigir o pico em 4,7 m, descartamos os valores de 2.101 edifícios e

3.121 pessoas e usamos no lugar a média entre os níveis de 4,6 m e 4,8 m, do mesmo jeito que já tínhamos feito antes. Já no início da série (dos níveis 3,0 m a 3,4 m), a população afetada estava registrada de forma inconsistente em 991, caindo bruscamente para 50 a partir de 3,5 m. Para não deixar o valor zerado nem manter a discrepância de 991, alteramos a população afetada nesse intervalo inicial para 20 pessoas. Dessa forma, o crescimento dos danos acompanha a subida do rio num padrão coerente.